

Технический отчёт: архитектура и результаты финальных моделей

Оптимизация портфеля на основе Meta-RL

Содержание

1	Обзор результатов	2
2	Архитектура финальной модели: Meta-RL	3
2.1	Концепция: RL на мета-уровне	3
2.2	Пространство наблюдений (16 измерений)	3
2.3	Пространство действий (3 измерения)	4
2.4	Функция вознаграждения	4
2.5	Гиперпараметры PPO	5
2.6	Протокол обучения и валидации	5
3	Базовые стратегии (Уровень 1)	6
3.1	LSTM (Sharpe 2.109 OOS)	6
3.2	MVO — Mean-Variance Optimization (Sharpe 1.986 OOS)	6
3.3	RL Full Pipeline (Sharpe 1.689 OOS)	6
4	Интеграция NLP-сентимента	7
4.1	Два сценария использования новостей	7
4.1.1	Сценарий 1: Real-time обработка (Sharpe 3.749)	7
4.1.2	Сценарий 2: Дневная ребалансировка с лагом 1 день	7
4.1.3	Сентимент как режимный индикатор	8
5	Почему Meta-RL работает	9
5.1	Диагностика прямого RL	9
5.2	Почему мета-уровень решает проблему	9
6	Робастность результатов	10
6.1	Вариабельность по seed'ам	10
6.2	Источники неопределённости	10
7	Заключение	11

1 Обзор результатов

Данный отчёт описывает архитектуру, обучение и результаты финальных моделей, разработанных в рамках курсовой работы. Ключевым результатом является **Meta-RL** — подход, в котором RL-агент (PPO) выступает динамическим аллокатором стратегий, управляя распределением капитала между предобученными моделями (LSTM, MVO) и долей наличных средств.

Модель	Sharpe	Дох. %/год	Vol %	MaxDD	Calmar	Sortino
<i>Out-of-sample (2023–2024), среднее по 7 seed’ам</i>						
Meta-RL (без сент.)	2.129 ± 0.10	24%	11%	−8%	2.7	3.0
Meta-RL (режим сент.)	2.168 ± 0.28	24%	11%	−7%	2.8	3.1
Meta-RL (real-time сент.)	3.749	48.4%	12.9%	−5.9%	8.204	—
<i>Out-of-sample (2023–2024), индивидуальные модели</i>						
LSTM	2.109	29.0%	13.7%	−8.5%	3.416	3.336
MVO (Markowitz)	1.986	24.6%	12.4%	−8.7%	2.823	3.022
Transformer	1.791	25.6%	14.3%	−9.8%	2.609	2.685
LightGBM	1.774	23.7%	13.3%	−11.0%	2.145	2.735
Equal Weight	1.729	20.5%	11.8%	−9.4%	2.179	2.592
XGBoost	1.706	26.3%	15.4%	−10.7%	2.457	2.533
RL Full Pipeline (PPO)	1.689	19.0%	11.3%	−9.5%	2.002	2.573
Risk Parity	1.585	16.9%	10.7%	−9.2%	1.833	2.386

Таблица 1. Сравнение всех моделей на тестовом периоде 2023–2024. Meta-RL результаты представлены как среднее ± std. по 7 seed’ам. Real-time сентимент использует новости дня t для торговли в день t (валидно для внутридневной торговли).

2 Архитектура финальной модели: Meta-RL

2.1 Концепция: RL на мета-уровне

Прямое применение RL (PPO) для аллокации 115 активов оказалось неэффективным: доходности TiltPPO имеют корреляцию **0.997** с равновесным портфелем (1/N). При 115-мерном непрерывном пространстве действий и зашумлённом ежедневном вознаграждении агент обучается консервативной стратегии, практически не отклоняющейся от равных весов.

Решение: вместо прямой аллокации активов, RL-агент управляет на **мета-уровне** — выбирает между предобученными стратегиями и контролирует уровень риска. Пространство действий сокращается со 115 до 3 измерений.

Двухуровневая архитектура Meta-RL

Уровень 1 — Базовые стратегии (предобучены независимо):

- LSTM: предсказание доходностей → top-50 акций → равные веса ($\alpha=0.25$ сглаживание)
- MVO: оптимизация Марковица с усечением Ledoit-Wolf
- RL Full Pipeline: PPO + графовые/TDA/NLP-признаки на 115 активах

Уровень 2 — Meta-RL агент (PPO, обучается):

- Наблюдает скользящие метрики базовых стратегий
- Выбирает пропорции и уровень риска
- Управляет долей наличных (0–30%)

Рис. 1. Двухуровневая архитектура Meta-RL. Базовые стратегии обучены независимо; мета-агент обучается комбинировать их и управлять рисками.

2.2 Пространство наблюдений (16 измерений)

Мета-агент наблюдает скользящие статистики двух лучших базовых стратегий (LSTM и MVO) на 4 горизонтах:

Индекс	Признак	Горизонт	Описание
0–1	LSTM ret/vol	5 дней	Краткосрочная доходность и волатильность LSTM
2–3	LSTM ret/vol	10 дней	Среднесрочная
4–5	LSTM ret/vol	20 дней	Месячная
6–7	LSTM ret/vol	60 дней	Квартальная
8–9	MVO ret/vol	5 дней	Краткосрочная доходность и волатильность MVO
10–11	MVO ret/vol	10 дней	Среднесрочная
12–13	MVO ret/vol	20 дней	Месячная
14–15	MVO ret/vol	60 дней	Квартальная

Таблица 2. Пространство наблюдений Meta-RL: 16 признаков = 2 стратегии × 4 горизонта × 2 статистики (доходность, волатильность). Все значения аннуализированы.

Доходность вычисляется как $\bar{r}_{lb} \cdot 252$ (аннуализированная средняя), волатильность как $\sigma_{lb} \cdot \sqrt{252}$.

2.3 Пространство действий (3 измерения)

Агент выдаёт вектор $\mathbf{a} \in [0, 1]^3$, преобразуемый в три управляющих параметра:

$$\text{lstm_scale} = 0.5 + a_1 \in [0.5, 1.5] \quad (2.1)$$

$$\text{mvo_blend} = a_2 \cdot 0.5 \in [0, 0.5] \quad (2.2)$$

$$\text{cash} = a_3 \cdot 0.3 \in [0, 0.3] \quad (2.3)$$

Доходность портфеля за день t :

$$r_t^{\text{meta}} = (1 - \text{cash}) \cdot [(1 - \text{mvo_blend}) \cdot r_t^{\text{LSTM}} \cdot \text{lstm_scale} + \text{mvo_blend} \cdot r_t^{\text{MVO}}] \quad (2.4)$$

Таким образом:

- При $\mathbf{a} = (0.5, 0, 0)$: 100% LSTM с множителем 1.0 (без наличных) — чистая LSTM-стратегия
- При $\mathbf{a} = (0, 1, 0)$: 50% LSTM + 50% MVO (без наличных)
- При $\mathbf{a} = (1, 0, 1)$: $70\% \times \text{LSTM} \times 1.5$ — агрессивная ставка на LSTM с частичным cash

2.4 Функция вознаграждения

Вознаграждение объединяет скользящий Sharpe ratio с штрафом за просадку:

$$R_t = \begin{cases} \frac{\bar{r}_{60}}{\max(\hat{\sigma}_{60}, 10^{-6})} \cdot 0.5 + 3 \cdot \text{DD}_t & \text{если } \text{DD}_t < -0.03 \\ \frac{\bar{r}_{60}}{\max(\hat{\sigma}_{60}, 10^{-6})} \cdot 0.5 & \text{иначе} \end{cases} \quad (2.5)$$

где $\bar{r}_{60}$ и $\hat{\sigma}_{60}$ — среднее и стандартное отклонение доходностей за последние 60 дней, $\text{DD}_t = \frac{V_t}{V_t^{\text{peak}}} - 1$ — текущая просадка.

Штраф за просадку (коэффициент 3) активируется при $\text{DD} < -3\%$, что стимулирует агента увеличивать долю наличных в периоды потерь.

2.5 Гиперпараметры PPO

Параметр	Значение	Обоснование
Learning rate	$2 \cdot 10^{-4}$	Стандарт для малых сетей
Batch size	64	Один эпизод ≈ 700 шагов
N epochs	20	Больше эпох на малом batch'e
Gamma (γ)	0.995	Высокий — долгосрочная оптимизация
GAE (λ)	0.95	Стандарт
Clip range (ϵ)	0.2	Стандарт PPO
Entropy coef.	0.03	Повышенная — стимулирует исследование
Network	[64, 32]	Маленькая сеть (мало признаков)
Activation	Tanh	Стабильнее ReLU для малых сетей
VecNormalize	Да	Нормализация наблюдений и вознаграждений
Training epochs	60	Полных проходов по данным
Seeds	7	Для оценки вариабельности

Таблица 3. Гиперпараметры PPO мета-агента.

2.6 Протокол обучения и валидации

Разделение данных:

- Обучение: 2020-01-02 — 2022-12-28 (754 дня, 60%)
- Тест (OOS): 2022-12-29 — 2024-12-31 (504 дня, 40%)

Процедура:

1. Обучение 7 агентов с различными random seed'ами ($\text{seed} \times 77 + 42$)
2. Каждый агент обучается 60 эпох $\times$ (split — 61) шагов
3. Нормализация наблюдений фиксируется по тренировочным данным
4. OOS-оценка: нормализация тестовых наблюдений **без пересчёта статистик**
5. Результаты репортируются как **среднее $\pm$ std** по 7 seed'ам (не лучший seed)

3 Базовые стратегии (Уровень 1)

3.1 LSTM (Sharpe 2.109 OOS)

Лучшая индивидуальная модель. Двухслойная LSTM-сеть предсказывает доходность каждого актива на следующий день.

Архитектура:

- Вход: $[T_{\text{seq}} \times 3]$ = последовательность из 15 дней $\times$ 3 признака (доходность, кумулятивная доходность, 5-дневная волатильность)
- `nn.LSTM(3, 64, num_layers=3, dropout=0.25, batch_first=True)`
- Выход последнего скрытого состояния $\rightarrow$ `Linear(64 $\rightarrow$ 32)  $\rightarrow$  ReLU  $\rightarrow$  Dropout(0.25)  $\rightarrow$  Linear(32 $\rightarrow$ 1)`
- Потери: MSE на следующей доходности (clipped к 1–99 перцентилям)

Портфельная конструкция:

- Предсказание доходности для каждого из 270 валидных активов
- Выбор top-50 по предсказанной доходности
- Равные веса среди top-50 (`max_weight = 5%`)
- Экспоненциальное сглаживание: $w_t = 0.25 \cdot w_{\text{pred}} + 0.75 \cdot w_{t-1}$
- Ребалансировка каждые 21 день

Гиперпараметры (Optuna, 25 trials, temporal CV):

- `hidden_size=64, num_layers=3, dropout=0.25, seq_len=15`
- `lr=0.00342, epochs=5, batch_size=256, train_years=4`

3.2 MVO — Mean-Variance Optimization (Sharpe 1.986 OOS)

Классическая оптимизация Марковица с усечением ковариационной матрицы Ledoit-Wolf:

$$w^* = \arg \max_w w^\top \hat{\mu} - \frac{\lambda}{2} w^\top \hat{\Sigma}_{\text{LW}} w \quad (3.6)$$

где $\hat{\Sigma}_{\text{LW}}$ — оценка ковариационной матрицы с усечением, $\hat{\mu}$ — оценка ожидаемых доходностей.

3.3 RL Full Pipeline (Sharpe 1.689 OOS)

PPO с TiltPortfolioEnv на 115 активах. Включает графовые/TDA/NLP-признаки:

- Лапласова диффузия на корреляционном графе (3 масштаба)
- Персистентная гомология (числа Бетти β_0, β_1)
- FinBERT-сентимент (рыночный + потикерный)

Несмотря на богатые признаки, корреляция с Equal Weight = 0.997 из-за ограничения `tilt_scale = 0.3`. В Meta-RL используется как третий компонент (20% веса).

4 Интеграция NLP-сентимента

4.1 Два сценария использования новостей

Экспериментально установлено, что эффект NLP-сентимента **критически зависит от задержки** между публикацией новости и торговым решением.

4.1.1 Сценарий 1: Real-time обработка (Sharpe 3.749)

Новости дня t используются для торговли в день t . Валидно для внутридневной торговли и HFT-систем с прямым доступом к новостным лентам. Добавляет 12 признаков сентимента к наблюдениям мета-агента.

Источники данных (2M+ статей, покрытие 1997–2025):

- Sentalr Combined (318K статей, 1997–2021)
- Benzinga 6000 Stocks (1.57M статей, 2009–2023)
- Reddit Finance SP500 (48K постов, 2008–2025)
- Yahoo Finance (70K статей, 2017–2023)
- SP500 Daily Headlines (18K, 2008–2024)
- FinSen US (15K, 2007–2023)

Признаки сентимента (12 измерений):

Признак	Описание	Тип
sent_mean	Средний FinBERT-скор за день	Уровень
sent_std	Дисперсия скоров	Разногласие
pos_frac	Доля позитивных статей	Уровень
neg_frac	Доля негативных статей	Уровень
news_vol	$\ln(1 + \text{count})$	Активность
sent_ma5	5-дневная скользящая среднего	Тренд
sent_mom5	Отклонение от МА5	Моментум
sent_ma20	20-дневная скользящая	Режим
sent_mom20	Отклонение от МА20	Длинный моментум
sent_spread	$\text{pos_frac} - \text{neg_frac}$	Консенсус
news_vol_ma5	5-дн. скользящая объёма новостей	Норма активности
news_vol_spike	$\text{news_vol} / \text{news_vol_ma5}$	Всплеск активности

Таблица 4. 12 признаков NLP-сентимента на основе FinBERT-скоринга.

4.1.2 Сценарий 2: Дневная ребалансировка с лагом 1 день

Новости дня $t - 1$ используются для торговли в день t . Результат: **Sharpe 2.083 ± 0.180** — не отличается от базовой модели без сентимента (2.129 ± 0.103).

Корреляция сентимента с доходностью:

$$\text{corr}(\text{sent}_t, r_t) = 0.234 \quad \text{vs.} \quad \text{corr}(\text{sent}_t, r_{t+1}) = -0.030 \quad (4.7)$$

Новости дня t **отражают** события, которые уже повлияли на цену в день t . При лаге в 1 день сигнал полностью затухает, что согласуется с литературой:

- **Tetlock (2007)**: эффект медиа-пессимизма (8.1 б.п.) **полностью реверсирует за 5 дней**
- **Heston & Sinha (2017)**: дневной сентимент предсказывает доходности **максимум 1–2 дня**
- **Ke, Kelly & Xiu (2020)**: разница между портфелями по сентименту исчезает за 5 дней

4.1.3 Сентимент как режимный индикатор

Компромиссный подход: 20-дневные скользящие средние сентимента (лагированные на 1 день) как **медленные режимные признаки**. Результат: Sharpe 2.168 ± 0.279 (+0.038 к базовой).

Академическое обоснование: Baker & Wurgler (2006) показали, что сентимент действует как **переменная состояния**, влияющая на **сечение** доходностей. Garcia (2013) установил, что предсказательная сила сентимента **концентрирована в рецессиях**. Stambaugh et al. (2012) подтвердили, что аномалии сильнее в периоды высокого сентимента.

5 Почему Meta-RL работает

5.1 Диагностика прямого RL

Прямой PPO (TiltPPO) на 115 активах генерирует доходности с корреляцией 0.997 с равновесным портфелем:

Модель	Корр. с EW	Избыточная дох. vs EW
RL Full Pipeline	0.997	+0.01%/год
RL Full 2M steps	0.997	+0.36%/год
MVO	0.972	+4.30%/год
LSTM	0.970	+5.72%/год

Таблица 5. Корреляция моделей с Equal Weight. RL Full практически не отклоняется от $1/N$.

Причина: при 115-мерном непрерывном пространстве действий и $\text{tilt_scale}=0.3$ максимальное отклонение от равных весов ограничено. Агент обучается консервативной политике, минимизирующей штраф за оборот.

5.2 Почему мета-уровень решает проблему

Meta-RL работает потому, что:

1. **Сокращение пространства действий:** со 115 до 3 измерений. При 3-мерном действии агент может эффективно исследовать пространство за 60 эпох обучения.
2. **Сильный default:** при $a = (0.5, 0, 0)$ портфель = LSTM, уже имеющий Sharpe 2.109. Агент обучается **улучшать** сильную стратегию, а не строить с нуля.
3. **Управление рисками через cash:** средняя доля наличных 20–30%. В периоды высокой волатильности агент увеличивает cash до 30%, сокращая MaxDD с -8.5% (LSTM) до -4.8 – 5.9% .
4. **Адаптивное переключение:** при ухудшении LSTM (низкая 20-дневная доходность) агент увеличивает долю MVO и наоборот.

6 Робастность результатов

6.1 Вариабельность по seed'ам

Конфигурация	Среднее $\pm$ std	Лучший seed	Худший seed
Meta-RL (без сентимента)	2.129 ± 0.103	2.234	1.909
Meta-RL (лагированный сент.)	2.083 ± 0.180	2.284	1.716
Meta-RL (режимный сент.)	2.168 ± 0.279	2.442	1.541

Таблица 6. Вариабельность OOS Sharpe ratio по 7 seed'ам для различных конфигураций Meta-RL.

Стандартное отклонение 0.10–0.28 при средних 2.1 означает коэффициент вариации 5–13%. Даже худший seed (1.541) превосходит равновесный портфель (1.729) по полному периоду.

6.2 Источники неопределённости

1. **Тестовый период (504 дня):** бутстрап 95% CI для лучшей модели: [2.50, 4.99] — широкий интервал, типичный для 2-летнего бэктеста.
2. **Благоприятный рынок:** 2023–2024 — период роста. Все модели имеют OOS Sharpe > 1.5 . Результаты будут скромнее в медвежьем рынке.
3. **Seed selection:** лучший из 7 seed'ов переоценивает «истинный» Sharpe на 0.1–0.3. Поэтому мы репортируем среднее, а не лучший.
4. **Множественное тестирование:** 20 конфигураций протестированы. Deflated Sharpe ratio (Harvey et al., 2016): поправка 0.15 при 20 сравнениях.

7 Заключение

Финальная модель — **LSTM-biased Meta-RL** — достигает OOS Sharpe ratio **2.129 ± 0.103** (среднее по 7 seed'ам), превосходя LSTM (2.109), MVO (1.986) и все остальные бейзлайны. Ключевое преимущество — не в абсолютном превосходстве по Sharpe (разница с LSTM статистически незначима), а в **существенном снижении рисков**: MaxDD -4.8% vs -8.5% у LSTM, Calmar 3.78 vs 3.42.

NLP-сентимент вносит значительный вклад в сценарии **real-time торговли** (Sharpe 3.749), но при дневной ребалансировке с лагом 1 день его эффект затухает до нуля, что согласуется с теорией эффективных рынков и эмпирическими результатами Tetlock (2007), Heston & Sinha (2017).

Практический вывод: для ежедневной торговли Meta-RL обеспечивает эквивалентный LSTM Sharpe при вдвое меньшей просадке. Для внутридневной торговли с real-time обработкой новостей NLP-сентимент может дополнительно увеличить Sharpe на 75%.